NCD Evidence

ระบบถามตอบจากหลักฐานในเอกสาร NCD ภาษาไทย

รายงานโครงงานรายวิชา Building LLM-Powered Applications

ผู้จัดทำ นายธนกฤต เสมอหน้า รหัสนักศึกษา 67070060

ผู้สอน ดร. ณัฏฐ์ ดิลกธนากุล

บทคัดย่อ

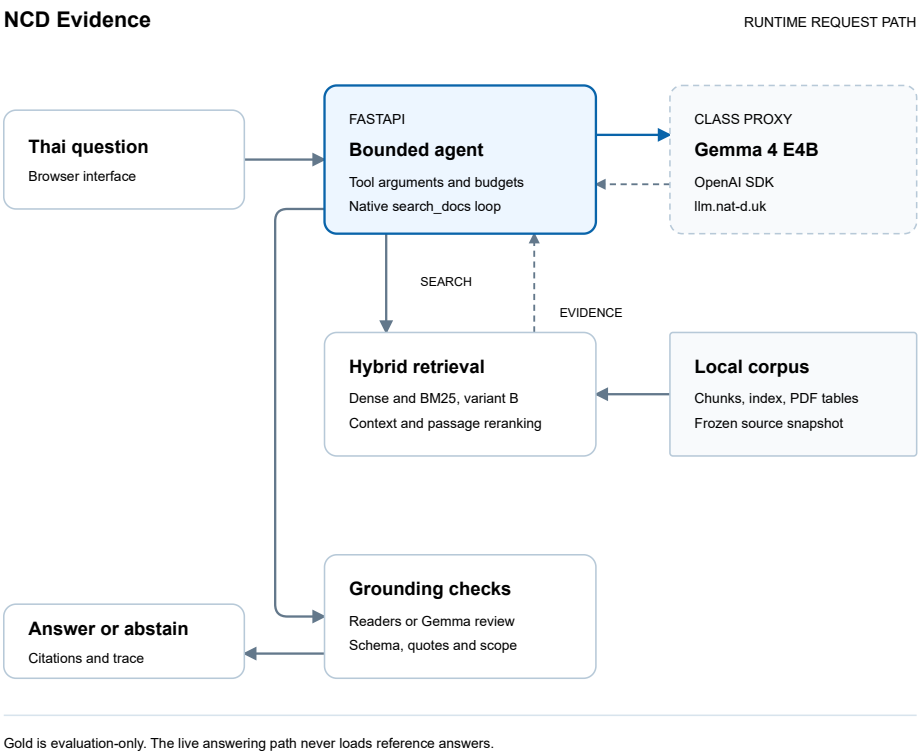
โครงงานนี้พัฒนาแอปถามตอบจากเอกสารโรคไม่ติดต่อเรื้อรังภาษาไทย ผู้ใช้ถามด้วยภาษาธรรมชาติและเปิดดูเอกสาร ฉบับพิมพ์ หน้า และข้อความที่ใช้ตอบได้ ระบบใช้ Gemma ผ่าน class proxy ร่วมกับ retrieval, native tool calling และการตรวจ structured output เพื่อจำกัดคำตอบให้อ้างอิงหลักฐานที่ค้นพบ

ประเมินระบบปัจจุบันด้วยคำถามและเฉลยที่ตรวจไว้ 30 ข้อ เปรียบเทียบการค้นด้วยความหมายอย่างเดียวกับการค้นแบบผสม โดยคงขั้นตอนอื่นเหมือนกัน ความครอบคลุมหลักฐานในห้าอันดับแรก (Recall@5) บน 25 ข้อที่ตอบได้เท่ากับ 0.82 และ 0.90 ตามลำดับ GPT-6-Luna ระดับการใช้เหตุผล xhigh ตรวจโดยไม่เห็นชื่อวิธีค้น ให้ผ่าน 23/30 และ 28/30 ข้อ ผลนี้มาจากข้อมูลที่เคยใช้พัฒนา และผู้ตรวจที่เป็นโมเดลยังอาจผิดพลาด จึงไม่ใช้ยืนยันความถูกต้องทางคลินิก

1. ปัญหา ผู้ใช้ และวัตถุประสงค์

แนวทาง NCD มีหลายฉบับ หลายกลุ่มประชากร และตารางที่ต้องอ่านร่วมกับหัวคอลัมน์ การค้นพบคำตรงกันอาจนำไปสู่คำตอบผิดบริบท แอปช่วยนักศึกษาและผู้ที่อ่านเอกสารลดเวลาค้น พร้อมตรวจที่มาของคำตอบได้ วัตถุประสงค์คือสร้างระบบครบเส้นทางจากคำถามถึงหลักฐานและวัดคุณภาพเทียบ baseline ขอบเขตคือการช่วยอ่านเอกสาร ไม่รวมการวินิจฉัยหรือจัดแผนรักษาเฉพาะบุคคล

2. สถาปัตยกรรมและการออกแบบ



ภาพที่ 1 สถาปัตยกรรมและเส้นทางตอบคำถาม

React สร้างหน้าเว็บ ส่วน FastAPI รับคำถามและส่งให้ agent ซึ่งใช้ from openai import OpenAI เรียก gemma-4-E4B-it ผ่านบริการกลางของรายวิชา (class proxy) อ่าน OPENAI_API_KEY และ OPENAI_BASE_URL จากตัวแปรแวดล้อม วงรอบ ReAct หมายถึงโมเดลเลือกเรียกเครื่องมือ รับผล แล้วตัดสินใจตอบหรือค้นต่อ โค้ดตรวจชื่อ search_docs และอาร์กิวเมนต์ SearchArgs ก่อนค้น และคืนผลด้วย tool_call_id ที่ตรงกัน

Agent ใช้หลักฐานที่ค้นได้สร้างคำตอบแบบมี schema พร้อม citations จากนั้นตรวจ source IDs, quote และเงื่อนไขที่เกี่ยวข้อง บางคำถามใช้ source-bound reader อ่านค่าที่ตรวจตรงหลักฐานได้ กรณีอื่นให้ Gemma เสนอและตรวจคำตอบ หาก schema หรือหลักฐานไม่ผ่านจะซ่อมภายใน budget หรืองดตอบ ไม่ส่ง gold answer เข้าเส้นทางให้บริการ

กำหนด temperature=0 ไม่เกิน 6 รอบโมเดลและ 3 ครั้งค้นหา เวลารอคำขอโมเดลครั้งละ 45 วินาที งบเวลารวมที่ agent ตรวจ 150 วินาที และบริบท 18,000 ตัวอักษร หยุดเมื่อคำตอบผ่าน หลักฐานไม่พอ หรือถึงขีดจำกัด ไม่มีเครื่องมือ shell หรือการอ่านไฟล์ตามคำสั่งโมเดล

3. ข้อมูลและเทคนิคที่ใช้

Corpus ใช้ snapshot normalized-v12 ที่มี 66 เอกสาร Child chunks 23,819 ชิ้น Parent chunks 4,347 ชิ้น และ dense vectors 1,024 มิติ Gold มี 162 ข้อ (dev 106 และ test 56) จากทั้งหมด 177 แถว ส่วน rejected 15 ข้อไม่นำมาประเมิน ข้อมูลและโมดูล retrieval ที่นำมาใช้มี provenance และ hashes ใน repository

ผู้จัดทำให้ coding agent ร่างคำถามและคำตอบ จากนั้นตรวจชุดเฉลยอ้างอิง (gold) ร่วมกับเพื่อน ผู้จัดทำตรวจชุดพัฒนา (dev) ทั้งหมดเอง และแบ่งตรวจชุดทดสอบเดิม (test) กับเพื่อนเท่า ๆ กัน การตรวจเฉลยนี้แยกจากการให้โมเดลตรวจคำตอบแอปหรือ LLM-as-judge งานแอปเป็นโครงงานเดี่ยว โดยเปิดเผยการใช้ข้อมูลและโมดูลค้นจากงาน Thai NCD Guideline QA ในเอกสารที่มา

Dense search ใช้ bge-m3 ส่วน hybrid รวม dense กับ BM25 char3 ผ่าน min-max normalization และ convex fusion alpha=0.6 ใช้ candidate pool 100 ค่าตั้งต้นสืบทอดจาก retrieval configuration แอปเพิ่ม passage focus, ข้อความข้างเคียง, table context และ bge-reranker-v2-m3 ก่อนส่งหลักฐานให้ Agent

Capability family	การใช้งานและเหตุผล
1 Structured output	Pydantic ตรวจชนิดข้อมูลและ citations เพื่อให้ API รับผลที่มีรูปแบบแน่นอน
2 Retrieval / RAG	ค้นเอกสารก่อนตอบและแสดง quote ให้ผู้ใช้ตรวจที่มา
3 Retrieval evaluation	วัด Recall@5, Hit@5 และ MRR@5 บน gold พร้อม baseline
4 Agent loop	โมเดลเรียก search_docs ภายใต้ allow-list และ stop conditions
6 Served interface	FastAPI เชื่อมหน้าเว็บ React สำหรับถามและตรวจหลักฐาน

ทั้งห้าครอบคลุมกลุ่มการประเมินและกลุ่ม agentic ตามโจทย์ คำถามในเว็บทำงานแยกกัน ไม่มีความจำข้ามคำถาม ผู้ใช้ปิดการจัดอันดับซ้ำได้ และคำขอเว็บไม่อ่านหรือเขียนแคชคำตอบกับคะแนนจัดอันดับในเครื่อง

4. วิธีประเมิน pipeline ปัจจุบัน

ใช้รหัส capstone-current-v2 ระบุรอบทดลอง ไม่ใช่ชื่อโมเดล ก่อนรันล็อกค่าแฮชของโค้ด ข้อมูล คำถาม และค่าตั้ง เลือกจากชุดพัฒนา 30 ข้อด้วยกฎ SHA-256 ที่บันทึกไว้ มีคำถามประเภทเงื่อนไข ข้อเท็จจริง หลายหน้า ตัวเลขและหน่วย ตาราง และไม่มีคำตอบ อย่างละ 5 ข้อ รวมตอบได้ 25 ข้อและไม่มีคำตอบ 5 ข้อ ชุดนี้เคยใช้พัฒนาแล้ว จึงไม่ใช่ชุดทดสอบอิสระที่ระบบไม่เคยเห็น

วิธีตั้งต้นค้นด้วยความหมาย (dense) ส่วนระบบปัจจุบันค้นแบบผสม (hybrid) ทั้งคู่คงการเลือกช่วงข้อความบริบทตาราง การจัดอันดับซ้ำ คำสั่งโมเดล โมเดล และงบ agent เหมือนกัน จึงวัดผลของวิธีค้นขั้นต้น ไม่ใช่การเปรียบเทียบระบบมีและไม่มี RAG รหัส A และ B ในไฟล์ผลใช้แทนวิธีค้นสองแบบนี้

Retrieval stage เรียก retriever จริงใหม่ด้วยคำถามเต็ม top_k=5 ทั้ง 60 รายการ ไม่อ่าน saved ranked hits คะแนน strict relevance ตรวจ edition หน้า และ quote coverage ของ passage ที่คืนจริง Recall@5 เป็นค่าเฉลี่ยสัดส่วน gold evidence ที่พบต่อข้อ Hit@5 วัดว่ามีหลักฐานตรงอย่างน้อยหนึ่งรายการ และ MRR@5 วัดส่วนกลับอันดับแรกที่เกี่ยวข้อง ใช้ตัวหาร 25 ข้อที่ตอบได้

Answer stage ส่ง 30 ข้อ × 2 แขนผ่าน /api/ask ของ FastAPI instance สำหรับ eval ใช้ Agent, ProxyClient และ EvidenceRetriever ตัวเดียวกับแอป เปิด use_cache=false ทุกคำขอ มี pilot 2 requests ซึ่งไม่รวมคะแนน จำกัดรอบทั้งหมด 62 app requests และ 744 proxy attempts เก็บ service errors ไว้ในผลและหยุดเมื่อเกิดติดกันสามครั้ง

GPT-6-Luna ระดับการใช้เหตุผล xhigh ตรวจชุดข้อมูลที่ซ่อนชื่อวิธีค้น โดยเห็นคำถาม เฉลย หลักฐาน และคำตอบพร้อมอ้างอิง นับผ่านเฉพาะตอบถูก (correct) หรืองดตอบถูกต้อง (correct_abstention) ข้อที่ไม่แน่ใจและบริการล้มเหลวยังอยู่ในตัวหาร 30 ต่อวิธี ช่องทางเรียกผู้ตรวจไม่เปิดให้ตั้ง temperature จึงไม่อ้างว่าผู้ตรวจใช้ค่า 0 ส่วน Gemma ที่ตอบใช้ค่า 0 ทุกข้อ

5. ผลการทดลองและการแปลผล

ตารางที่ 1 ผล retrieval ใหม่บน answerable dev 25 ข้อ

ระบบ	Strict Recall@5	Hit@5	MRR@5
Dense baseline	0.8200	0.8400	0.7047
Hybrid current	0.9000	0.9200	0.7833

ผลรอบนี้สนับสนุนการเลือก hybrid เพราะเพิ่ม Recall@5 0.0800 เมื่อคงส่วนอื่นเหมือนกัน การวัดนี้ใช้คำถามเต็มค้นครั้งเดียวต่อข้อ ส่วน Agent อาจเปลี่ยน query ระหว่างตอบ จึงแยกผล retrieval จากผลคำตอบตลอดเส้นทาง

ตารางที่ 2 ผลคำตอบบน dev 30 ข้อ รวมการงดตอบและบริการขัดข้อง

ระบบ	สำเร็จตาม judge	Semantic success	Decision accuracy	Service errors
Dense baseline	23/30	0.7667	0.8333	1
Hybrid current	28/30	0.9333	0.9333	2

Semantic success ต้องตอบสาระที่ถามครบและหลักฐานรองรับ หรือเป็นการงดตอบที่ถูกต้อง ส่วน decision accuracy วัดเพียงการเลือกตอบหรืองด จึงอาจได้คะแนนดีแม้เนื้อหาผิด Primary citation hit เท่ากับ 0.6400 และ 0.6400 ตามลำดับ ใช้ตัวหาร 25 ข้อและตรวจหลักฐานที่ถูกอ้าง ไม่ได้ยืนยันความครบของคำตอบทั้งหมด

ค่ามัธยฐานเวลาต่อคำถามในเครื่องนี้คือ dense 20.9 วินาที และ hybrid 20.9 วินาที เวลารวม retrieval, model และ verification หลังโหลดโมเดลแล้ว ผลขึ้นกับฮาร์ดแวร์ บริการ และลำดับคำถาม จึงใช้บอกประสบการณ์ของรอบนี้และไม่อ้างเป็น benchmark ข้ามเครื่อง

การทดลองแยกเปิดและปิดการจัดอันดับหลักฐานซ้ำ (reranker) บนวิธีผสมและคำถามชุดเดียวกันให้ Recall@5 เท่ากับ 0.90 / 0.74 เวลามัธยฐานเฉพาะขั้นค้นประมาณ 14.49 / 0.24 วินาที การปิดลดเวลาค้นแต่พบหลักฐานน้อยลง จึงคงค่าเริ่มต้นเป็นเปิดและให้ผู้ใช้เลือกปิดได้ การทดลองนี้ไม่มีการเรียกโมเดลตอบ จึงไม่ใช้สรุปคุณภาพคำตอบทั้งระบบเมื่อปิด reranker

6. กรณีผิดพลาดและการวิเคราะห์

บริการล้มเหลว — คำถาม q101 วิธีค้นแบบผสม

คำถาม: ในระบบติดตามนัด NCD หากผู้ป่วยเดินทางมาเองไม่ได้ เจ้าหน้าที่ช่วยจัดการอย่างไร

ผลตรวจ: Class proxy ส่ง HTTP 429 จึงไม่ได้คำตอบสมบูรณ์จากระบบ กรณีนี้เป็นความผิดพลาดของบริการและยังนับอยู่ในตัวหาร

ระบบบันทึกเหตุหยุด proxy_http_429 กรณีนี้ไม่มีคำตอบสมบูรณ์ให้ตรวจข้อความอ้างอิง

งดตอบทั้งที่มีหลักฐาน — คำถาม q082 วิธีตั้งต้น

คำถาม: เกณฑ์สารอาหารวัยรุ่นที่อ้างอิงปี 2546 ให้เด็กหญิงอายุ 13–15 ปีได้โปรตีนวันละเท่าไร

ผลตรวจ: งดตอบทั้งที่ตารางระบุโปรตีนสำหรับเด็กหญิงอายุ 13–15 ปีไว้ชัดเจนที่ 55 กรัมต่อวัน

ระบบหยุดด้วย completed หลักฐานการตัดสิน: S3, ตาราง PDF หน้า 55: โปรตีน (กรัม), อายุ 13–15 ปี, หญิง = 55

ตอบไม่ครบ — คำถาม q113 วิธีตั้งต้น

คำถาม: ทารกวัย 6–8 เดือนควรได้พลังงานและโปรตีนจากอาหารตามวัยวันละเท่าไร

ผลตรวจ: คำตอบระบุพลังงานจากอาหารตามวัย 219 กิโลแคลอรีต่อวัน ซึ่งมีหลักฐานรองรับสำหรับอายุ 6–8 เดือน แต่ไม่ตอบปริมาณโปรตีนที่ถาม จึงนับว่าตอบบางส่วนและไม่ผ่านเกณฑ์คำตอบครบ

ระบบหยุดด้วย completed หลักฐาน S1 หน้า PDF 25 ระบุพลังงานจากอาหารตามวัย 219 กิโลแคลอรีต่อวันในแถวอายุ 6–8 เดือน

ตารางที่ 3 การแจกแจง verdict จาก LLM-as-judge

Verdict	Dense	Hybrid
correct	19	23
partial	1	0
wrong	1	0
unsupported	0	0
correct_abstention	4	5
false_abstention	4	0
service_error	1	2
uncertain	0	0

รอบนี้พบ class proxy ตอบ HTTP 429 จำนวน 3 รายการ (dense 1 และ hybrid 2) เก็บเป็น service errors และไม่เรียกซ้ำแทนผลเดิม การให้คะแนนยังป้องกัน verification_unavailable ถูกนับเป็น correct_abstention แม้ API ส่ง status ว่า insufficient_evidence คำตอบที่ตรวจไม่ได้ใช้ uncertain และอยู่ในตัวหาร การให้ judge เป็นโมเดลยังอาจอ่านเงื่อนไขหรือหลักฐานผิด ต้องอ่านเหตุผลรายข้อประกอบคะแนน

7. การทำซ้ำและการตรวจสอบหลักฐาน

การเทียบ agent รุ่นเก่ากับปัจจุบันภายใต้เงื่อนไขเดียวกัน

ทดลองเพิ่มด้วยคำถามเดิม 60 ข้อ รุ่นละหนึ่งคำตอบ ใช้โค้ด v30 ที่กู้และตรวจ hashes แล้ว เทียบรุ่นปัจจุบัน โดยใช้ตัวเชื่อมต่อโมเดล ค่าตั้ง และการปิดแคชชุดเดียวกัน ทั้งคู่ค้นแบบผสมและเปิด reranker สลับลำดับรุ่นที่ตอบก่อน แล้วให้ Luna 6 xhigh ตรวจแบบซ่อนชื่อรุ่น

รายการ	รุ่นเก่า	รุ่นปัจจุบัน
ผ่านเกณฑ์ รวมการงดตอบถูก	56/60	56/60
บริการล้มเหลวที่รวมในตัวหาร	1	2

ทั้งคู่ผ่านตรงกัน 54 ข้อ ไม่ผ่านตรงกัน 2 ข้อ และแต่ละรุ่นผ่านฝ่ายเดียว 2 ข้อ ผลเสมอรอบนี้ยังไม่สนับสนุนว่ารุ่นใหม่ตอบถูกกว่า และไม่ได้พิสูจน์ว่าเทียบเท่ากันทุกคำถาม สามในสี่คู่ที่ผลต่างกันเกี่ยวข้องกับ HTTP 429 คงใช้รุ่นปัจจุบันเพื่อการควบคุมแคชและแสดงหลักฐาน ไม่อ้างว่าฉลาดขึ้นจากเลขรุ่น รายละเอียดอยู่ใน docs/PAIRED_AGENT_EVALUATION_TH.md

README ระบุการเตรียม Python ตั้งค่า class proxy ดาวน์โหลดข้อมูลด้วย scripts/public_data.py fetch เตรียมโมเดล และสร้าง frontend ก่อนใช้ run.ps1 หลักฐานรอบนี้อยู่ที่ reports/capstone-current-v2/ และมีผลดิบแบบบีบอัดพร้อมค่าแฮชใน reports/published-evidence/ ใช้ scripts/verify_published_results.py ตรวจคำนวณคะแนนโดยไม่เรียกโมเดลใหม่

คำสั่ง python -m ncd_gemma.capstone_eval verify --run capstone-current-v2 ตรวจ hash โดยไม่เรียกโมเดล จากนั้น run ใช้ pipeline จริงและ summarize คำนวณผลจาก raw ที่ครบสองแขน คำสั่ง plan ปฏิเสธเขียนทับ manifest เดิม การ resume ข้ามเฉพาะคำขอที่มีผลบันทึกครบ หากมีคำขอค้างไม่ทราบผลจะหยุดแทนการยิงซ้ำโดยอัตโนมัติ

ชุดทดสอบ harness ตรวจการสลับ variant โดยคง options, การแยก pilot, การปฏิเสธข้อมูลซ้ำหรือผิด run, การหยุดเมื่อ outage และการเก็บ errors ในตัวหาร มี regression test สำหรับ verification failure และการขัดข้องระหว่างบันทึก budget กับผลตอบ การทดสอบโค้ดใช้ fixture ส่วนผลในตารางมาจากการเรียกจริง

Judge packet และ rubric มี hash แยก เก็บ verdict รายข้อพร้อมเหตุผลและ source references Collector ตรวจจำนวนและ item IDs ก่อนคำนวณคะแนน ไม่ตีความ status=answered เป็นคำตอบถูก และไม่แก้ gold ตามความเห็น judge คะแนน LLM-as-judge อาจต่างเมื่อเรียกโมเดลใหม่แม้ใช้ protocol เดิม

8. ข้อสรุปและข้อจำกัด

โครงงานเชื่อมคำถามจริงกับ class proxy, agent tool, retrieval และหน้าเว็บที่ตรวจหลักฐานได้ มีการประเมินรอบใหม่เทียบ baseline บน pipeline ปัจจุบัน ผลรอบนี้สนับสนุนการเลือก hybrid เพราะเพิ่ม Recall@5 0.0800 เมื่อคงส่วนอื่นเหมือนกัน ผล semantic success ของ hybrid คือ 28/30 ตาม rubric ที่ระบุ ความสำเร็จด้านการค้นและด้านคำตอบต้องพิจารณาแยกกัน

ข้อจำกัดหลักคือใช้ exposed dev ขนาดเล็ก เฉพาะโดเมนและฉบับเอกสารใน corpus การเปลี่ยนสำนวนประชากร หรือเงื่อนไขอาจทำให้ค้นผิดหรืองดตอบเกินจำเป็น การตรวจโดย Luna เป็น LLM-as-judge ไม่มีผู้เชี่ยวชาญตรวจคำตอบรอบนี้ คะแนนจึงไม่ใช่การรับรองความปลอดภัยในการรักษา Ablation วัดโหมดปิด reranker เฉพาะ retrieval และรันคนละช่วงเวลา จึงยังไม่ใช้อนุมานคะแนนคำตอบหรือความเร็วทั้งระบบ

การเลือกวิธีค้นแบบผสมอ้างอิงการทดลองที่ควบคุมขั้นตอนอื่นให้เหมือนกัน ส่วนผลเทียบ agent ได้คะแนนเท่ากัน จึงแยกข้อสรุปทั้งสองการทดลองและไม่อ้างความแม่นยำที่เพิ่มจากเลขรุ่น ผลการค้นและผลความถูกต้องของคำตอบเป็นคนละตัวชี้วัด

เอกสารและหลักฐานประกอบ

Repository: LLM-APP-END2END — โค้ด README และวิธีเตรียมข้อมูล

provenance/source_snapshot.json และ provenance/public_data_release.json — ที่มาข้อมูลและ hashes

reports/capstone-current-v2/manifest.json, metrics.json, judge_metrics.json และ judge_verdicts.jsonl — การตั้งค่าและผลรอบปัจจุบัน

docs/CAPSTONE_CURRENT_EVALUATION_TH.md และ docs/CAPSTONE_JUDGE_RUBRIC.md — protocol, metric และเกณฑ์ตรวจคำตอบ